

Pi 无额外 Skill 基线测试报告

1 结论摘要

本报告对应统一测试集 v2，执行时间为 2026-09-27 至 2026-10-01 (UTC)。开发集 600 对、正式集 1200 对，共 **3600 条有效轨迹**，全部完成；另有 24 条 canary 准入，不混入成绩。2026-10-01 完成交付前复审，1800 对初态和稳定后状态一致，冻结配置及权重哈希核验通过。

正式集范围	每方法条数	直接 VLA		Pi 差值 (百分点)
全部	1200	444 (37.00%)	454 (37.83%)	+0.83
标准四组	400	339 (84.75%)	338 (84.50%)	-0.25
Pro 八组	800	105 (13.13%)	116 (14.50%)	+1.38

上表为**终态成功**。正式集整体配对差值的任务聚类 95% 区间为 **[-1.42, +3.08]** 个百分点，包含零；不能据此宣称无额外 skill 的 Pi 带来稳定成功率提升，也不意味着两方法等效。

Pi 在 62 对中成功而直接 VLA 失败，52 对出现相反结果，净增 10 次成功。Pi 平均动作从 330 降至 282.01 步（减少 14.54%），但平均每条耗时从 13.50 秒增至 159.64 秒（11.82 倍）。Pi 正式集误报完成 159/1200（13.25%）；在 603 次声称完成中，159 次终态不成功（26.37%）。因此，动作更少不等于更快、更便宜或完成判断更可靠。

2 固定方法与预算

B0: 同一冻结 VLA 接收完整任务指令，执行至动作预算。**B1:** 原生 Pi 0.85.1、deepseek-flash 高推理与原生视觉，调用同一 VLA 并自行决定结束。VLA 为 lerobot/pi05_libero_finetuned_v044，不是 RPent 的 RLinf 权重。

Pi 保留 read/bash/edit/write，机器人工具仅为 robot_observe、robot_execute_vla、robot_finish。skills 与 contextFiles 为空；无额外机器人 skill、恢复模块或成功真值反馈。双相机图像、本体状态和时间戳可观察。每个动作块 32 步，每次最多 4 块；动作预算为 Spatial 220、Object 280、Goal 300、Long 520，Pro 沿用对应家族预算。Pi 每条墙钟上限 30 分钟，单次输出上限 65,536 token。环境/策略种子为 7。

真值只用于私有评分，不触发提前停止。B0 可能先成功后破坏目标，因此这些结果不能直接等同于首次成功即停止的论文成绩。时间为记录中的每条执行墙钟耗时，含 API 等待与原生重试；不是 GPU 纯推理时间，也不是整个任务历时。

3 正式集：逐组结果

每组每方法 100 条（10 个任务、每任务 10 个初态）。曾达成为任一物理步成功；终态为结束时成功。误报仅针对 Pi 的完成声明，B0 无此声明。费用为美元估算，详见费用页。

环境	方法	曾达成	终态	误报	平均步	平均秒	API 估算
Spatial	B0	94	80	–	220.0	11.6	0
	B1	92	88	10	150.8	97.3	9.69
Object	B0	98	98	–	280.0	11.6	0
	B1	97	97	0	187.7	110.6	14.91
Goal	B0	94	83	–	300.0	11.4	0
	B1	89	84	5	190.6	106.3	12.49
Long	B0	96	78	–	520.0	18.9	0
	B1	90	69	19	390.6	195.3	27.72
Spatial Task	B0	36	35	–	220.0	11.8	0
	B1	37	37	10	194.8	159.4	20.69
Spatial Swap	B0	27	19	–	220.0	12.0	0
	B1	26	26	25	195.6	141.9	18.91
Object Task	B0	10	10	–	280.0	12.2	0
	B1	10	10	10	268.2	205.5	31.48
Object Swap	B0	5	5	–	280.0	12.3	0
	B1	9	9	11	273.0	194.8	25.72
Goal Task	B0	17	5	–	300.0	11.7	0
	B1	13	2	21	289.2	155.6	21.15
Goal Swap	B0	19	17	–	300.0	11.5	0
	B1	19	19	14	265.1	127.4	15.03
Long Task	B0	18	14	–	520.0	18.6	0
	B1	15	12	29	469.5	219.5	34.43
Long Swap	B0	0	0	–	520.0	18.5	0
	B1	4	1	5	508.8	201.9	28.05

整体曾达成：B0 514/1200（42.83%），B1 501/1200（41.75%）。整体终态：B0 444/1200，B1 454/1200。两者指标方向不同，不能仅选取有利指标。Pi 的 Spatial 标准组终态较高、Long 标准组较低；这些分组差异为描述性结果，未进行多重比较显著性声明。

4 开发集：逐组结果

每组每方法 50 条（10 个任务、每任务 5 个初态）。开发成绩独立报告，不与正式集混合。

环境	方法	曾达成	终态	误报	平均步	平均秒	API 估算
Spatial	B0	46	42	–	220.0	12.1	0
	B1	45	45	3	152.6	82.2	4.44
Object	B0	49	49	–	280.0	12.1	0
	B1	50	49	1	186.6	86.0	5.92
Goal	B0	49	42	–	300.0	11.6	0
	B1	39	35	6	203.5	86.3	6.02
Long	B0	47	40	–	520.0	20.0	0
	B1	44	36	3	383.0	172.2	13.77
Spatial Task	B0	16	15	–	220.0	12.0	0
	B1	15	15	12	191.1	146.6	11.04
Spatial Swap	B0	12	10	–	220.0	12.3	0
	B1	10	8	16	197.2	129.4	9.80
Object Task	B0	5	5	–	280.0	12.2	0
	B1	5	5	7	265.0	185.9	16.78
Object Swap	B0	3	3	–	280.0	12.2	0
	B1	7	7	10	271.4	190.0	15.23
Goal Task	B0	7	1	–	300.0	11.8	0
	B1	9	1	13	288.1	146.9	11.87
Goal Swap	B0	11	11	–	300.0	11.5	0
	B1	6	6	4	274.0	122.4	9.95
Long Task	B0	10	7	–	520.0	19.0	0
	B1	12	12	11	461.1	178.3	14.40
Long Swap	B0	1	0	–	520.0	19.0	0
	B1	1	0	4	507.5	177.3	13.27

整体终态：B0 225/600（37.50%），B1 219/600（36.50%）。曾达成：B0 256/600（42.67%），B1 243/600（40.50%）。Pi 误报 90/600（15.00%），声称完成 304 次中的误报占 29.61%。平均动作 B0 330、B1 281.76；平均秒数 B0 13.81、B1 141.96。

5 配对统计与不确定性

将同一任务、扰动组与初态的两方法配对。这里的“救回”只表示 B0 失败而 B1 成功的配对差异;“损害”表示相反结果，不是在同一条失败轨迹上实施干预后的因果恢复率。

划分	范围	对数	救回	损害	差值 pp	95% 聚类区间 pp
开发	全部	600	33	39	-1.00	[-5.17, 2.50]
	标准	200	14	22	-4.00	[-11.50, 2.50]
	Pro	400	19	17	+0.50	[-2.75, 4.00]
正式	全部	1200	62	52	+0.83	[-1.42, 3.08]
	标准	400	29	30	-0.25	[-4.50, 4.00]
	Pro	800	33	22	+1.38	[-0.75, 3.50]

按 40 个基础任务（家族、任务编号）聚类，Task/Swap 变体与所有初态保留在同一簇。对簇有放回抽样 20,000 次，种子 20261001，取配对终态差值的 2.5% 与 97.5% 分位数。各簇样本数平衡，因此簇均值与逐对均值一致。区间反映本测试集任务间差异，**不覆盖 API 多次随机重复、其他任务分布或真机迁移的不确定性**。正式集两者均成功 392 对、均失败 694 对；开发集分别为 186 与 342 对。

6 测试集与解释边界

12 组由四个标准家族及各自 Task/Swap 扰动组成。总体分数按本清单加权：标准占 1/3、Pro 占 2/3，不代表任意实际部署任务分布。开发初态为 0、1、2、47、48；正式初态为 7、44、17、11、24、27、14、38、49、32。正式与开发初态不重叠，**但不是 VLA 未见任务测试**，也不是 1200 个独立任务。

本轮没有按成功率调整提示、工具、模型或动作预算。标准输入采用官方 metadata 指令，Pro 输入采用实际扰动 BDDL。v1 曾在指令来源校验阶段失败，未执行模型；v2 仅修正标准指令来源，保留 v1 记录。该结果只覆盖本次最小工具 Pi；不代表加入 skill、额外感知或成熟机器人 Agent 后的上限。

为后续迭代建立的分层清单为每 Agent 24 条接口检查、240 条日常开发、600 条候选正式评估、1200 条最终正式评估。本次完整基线未缩减。候选 600 条属于最终 1200 条的子集，不能当成独立重复验证；正式子集不用于反复调参。复用本轮 B0 需要同样样本、模型、环境与预算。

7 费用与基础设施记录

用途	API 请求	正常返回	不确定/错误	美元估算含预留
开发有效 Pi	17559	17523	36	132.4927
正式有效 Pi	34707	34642	65	260.2798
Canary 准入	450	450	0	3.3881
归档无效原轨迹	96	77	19	7.7993
健康检查	2	2	0	0.000075
合计	52814	52694	120	403.9599

按归档的输入 0.30、输出 1.20 美元/百万 token 计算，全部输入按缓存未命中、峰时处理。2026-10-01 查阅 DeepSeek 官方定价页，确认该峰时价格仍与归档一致；官方另有更低的缓存命中及非峰时价格。以上为保守估算，不是账单实付，也不是严格保证的实际账单上界。正常返回请求估算 358.5227 美元，120 次不确定/错误请求保留 45.4372 美元预留；无未决 reserved 项。不确定请求的实际扣费未核实，不静默按零处理。没有获取账户账单；不含 GPU、服务器与电费。有效轨迹费用包含恢复后的替代轨迹，旧无效轨迹另列，避免遗漏或重复归入成绩。

官方价格来源（核查日期 2026-10-01）：https://api-docs.deepseek.com/quick_start/pricing/

接口故障与恢复：开发 Long task3/init0 的 Pi 原轨迹，以及正式 Object Task task7/init17 的 Pi 原轨迹，因上游连接错误未有效结束，分别独立版本化重测。重测沿用原模型、提示、预算与初态；核对有效性和初态哈希后替换规范结果，完整旧轨迹及费用保留在 invalid-attempts。仅有这两条作为无效原轨迹归档，未把未运行或接口无效条目算作 Agent 能力失败。

开发结束后，原进程因第二次环境 bootstrap 保护性退出，正式集尚未执行；改用新进程调用原冻结流程继续。没有修改策略或重封配置。原生自行恢复的网络错误仍保留在有效轨迹的耗时与费用里，因此本报告时延包含基础设施影响。

Pi 同轮并行提交有依赖的裁剪与读取所致 ENOENT，以及未承诺依赖的探测失败，没有据此改策略或补装能力。运行有效不等于每一个模型动作决策正确；低成功率也不单独归因于模型或工具的某一环节。

8 审计与可追溯归档

复审逐条检查清单覆盖与唯一性、每步私有成功真值和目标谓词一致性、动作步数与预算、配对初态及稳定状态哈希。1800 条有效 Pi 轨迹均记录图像输入（开发 600、正式 1200）；检查原生视觉请求与工具推理历史按原始返回内容回传。检查 skills/contextFiles 为空、工具集合恰为四个原生工具及三个机器人工具、高推理配置不变。Canary 已人工核对 12 组初末双相机与物理推进；全量审计不等于人工逐帧语义标注所有视频。

API 请求与返回名称均为 **deepseek-flash**；服务商可变别名无法冻结实际权重。文件系统 jail 不是完整网络隔离。审计支持既定接口与记录完整性，不构成对所有可能信息通道的形式化安全证明。

主实验位置：/root/autodl-tmp/experiments/pi-baseline-20260927-v2

development/ 与 evaluation/ 保存逐条结果、公共执行记录及私有评分记录；api/ 保存请求、响应和账本；invalid-attempts/ 保存无效原轨迹及替代映射。统计脚本和统计 JSON 与报告一起归档，可从 audit JSON 重算配对区间。

文件	SHA256
protocol-lock.json	4640b3f0e881e03d2614c2e154b2a955062139253195f3727e40512773464f5b
development-audit.json	c4317da7c90b813d2f559148dcd71053a6780cba601e7d558ca8f2b1fc1bfcfb
evaluation-audit.json	c0027443359bc06f13fc4a3e8b4a36f100f6ee8cbfe1ee50f23d60bb3befccef
ledger.json	eee34028d9fd9db44931fc27003d5f525b10b7f45ab2415372a13b715ed43a69

本报告替换旧 140 条基线报告，旧版先归档；不混入成熟 Agent 对照报告。仅同步本地与指定服务器，不推送 GitHub，不删除研究数据，不关闭服务器。